Java 核心技术(进阶)

第三章 高级文本处理

第三节 Java高级字符串处理

华东师范大学 陈良育

大纲

- 正则表达式
- 其他字符串操作
  - 集合和字符串互转
  - 字符串转义
  - 变量名字格式化
  - 从字符串到输入流

正则表达式(1)

- 如何识别给定字符串为合法的邮箱地址
  - a@b.com √
  - a@@b.com ×
  - a@b ×
  - @a.com ×
  - a@b@c.com ×
- 如何认定一个字符串满足一定的规律

正则表达式(2)

- 正则表达式(Regular Expression)
  - 规则表达式，计算机科学的一个基础概念
  - 用事先定义好的一些特定字符、及这些特定字符的组合，组成一个“规则字符串”
  - ^[A-Za-z]+$，代表着一个字符串，只能由26英文字母组成
  - 作用
    - 测试字符串内的模式
    - 识别/替换文本
    - 提取文本

正则表达式(3)

- 正则表达式独立于特定语言（Java, Perl, Python, PHP…）
- 正则表达式的匹配模板
  - 定界符
  - 原子
  - 特殊功能字符(元字符)
  - 模式修正符
- 推荐书籍：精通正则表达式(第三版)，Jeffrey E.F.Friedl著，余晟翻译，电子工业出版社，2012.

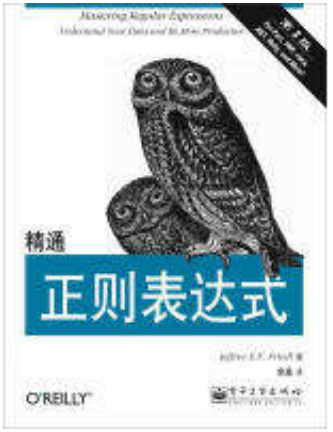

Java的正则表达式

- java.util.regex包
  - Pattern 正则表达式的编译表示
    - compile 编译一个正则表达式为Pattern对象
    - matcher 用Pattern对象匹配一个字符串，返回匹配结果
  - Matcher
    - Index Methods(位置方法) // start(), start(int group), end(), end(int group)
    - Study Methods(查找方法) // lookingAt(), find(), find(int start), matches()
    - Replacement Methods(替换方法) //replaceAll(String replacement)
- 查看例子

其他字符串操作

- 字符串和集合互转
  - [1,2,3], “1,2,3”
- 字符串转义
  - 对关键字符转义
- 变量名字格式化
  - 名字驼峰命名
- 字符串输入流
  - 将字符串转为一个输入流
  - 输入流可以定义为Scanner，这是Online Judge的实现原理

总结

- 灵活使用正则表达式
- 多使用第三方库：Apache Commons Lang. Guava等
  - github.com
  - mvnrepository.com
  - www.open-open.com
  - ……

代码(1) MatcherDemo.java


```
public class MatcherDemo {

    private static final String REGEX = "\\bdog\\b";   //\b表示边界
    private static final String INPUT = "dog dog dog doggie dogg";

    public static void main(String[] args) {
        //检查字符串里面有多少个dog
        Pattern p = Pattern.compile(REGEX);

        Matcher m = p.matcher(INPUT);
        int count = 0;
        while (m.find()) {
            count++;
            System.out.println("Match number " + count);
            System.out.println("start(): " + m.start());
            System.out.println("end(): " + m.end());
        }
    }
}
```

代码(2) MatchesLooking.java


```
public class MatchesLooking {

    private static final String REGEX = "foo";
    private static final String INPUT =
        "foo";
    private static Pattern pattern;
    private static Matcher matcher;

    public static void main(String[] args) {

        // Initialize
        pattern = Pattern.compile(REGEX);
        matcher = pattern.matcher(INPUT);

        System.out.println("Current REGEX is: "
                           + REGEX);
        System.out.println("Current INPUT is: "
                           + INPUT);

        System.out.println("lookingAt(): "
            + matcher.lookingAt());   //部分匹配
        System.out.println("matches(): "
            + matcher.matches());     //完全匹配
    }
}
```

代码(3) RegexDemo.java


```
public class RegexDemo {

    private static String REGEX = "a*b"; //*表示限定前面的a可以有0或者多个。
    private static String INPUT = "aabfooaabfooabfoobcdd";
    private static String REPLACE = "-";

    public static void main(String[] args) {
        Pattern p = Pattern.compile(REGEX);
        Matcher m = p.matcher(INPUT); // get a matcher object
        StringBuffer sb = new StringBuffer();
        //全部替换
        while(m.find()){
            m.appendReplacement(sb,REPLACE);
        }
        //将最后的尾巴字符串附加上
        m.appendTail(sb);
        System.out.println(sb.toString());
    }
}
```

代码(4) ReplaceDemo.java


```
public class ReplaceDemo {

    private static String REGEX = "dog";
    private static String INPUT =
        "The dog says meow. All dogs say meow.";
    private static String REPLACE = "cat";

    public static void main(String[] args) {
        Pattern p = Pattern.compile(REGEX);
        // get a matcher object
        Matcher m = p.matcher(INPUT);
        INPUT = m.replaceAll(REPLACE);   //把所有的dog都换成cat
        System.out.println(INPUT);
    }
}
```

代码(5) ReplaceDemo2.java


```
public class ReplaceDemo2 {

    private static String REGEX = "a*b"; //*表示限定前面的a可以有0或者多个。
    private static String INPUT =
        "aabfooaabfooabfoob";
    private static String REPLACE = "-";

    public static void main(String[] args) {
        Pattern p = Pattern.compile(REGEX);
        // get a matcher object
        Matcher m = p.matcher(INPUT);
        INPUT = m.replaceAll(REPLACE);
        System.out.println(INPUT);
    }
}
```

代码(6) RegexTest.java


```java
public class RegexTest {

    public static void main(String[] args) {

        regularExpression();
    }

    public static  void regularExpression() {
        String REGEX_EMAIL = "^\\w+((-\\w+)|(\\.\\w+))*@[A-Za-z0-9]+(([.\\-])[A-Za-z0-9]+)*\\.[A-Za-z0-9]+$";//email
        Pattern pattern = Pattern.compile(REGEX_EMAIL);

        String[] emails = new String[]{"123^@qq.com", "name_321@163.com", "+whatever*72@gmail.com"};
        for(String email : emails) {
            Matcher matcher = pattern.matcher(email);
            if (matcher.matches()) {
                System.out.println(email + " is valid email.");
            } else {
                System.out.println(email + " is not valid email.");
            }
        }
    }
}
```

代码(7) String2List.java


```java
public class String2List {

    public static void main(String[] args) {
        List<String> names = new LinkedList<String>();
        names.add("Xiaohong");
        names.add("Xiaoming");
        names.add("Daming");
        names.add("Xiaohei");

        //从ArrayList变到字符串
        String str1 = String.join(",", names);  //String.join, JDK 8 引入
        System.out.println(str1);

        String str2 = StringUtils.join(names, ",");  //Apache Commons Lang
        System.out.println(str2);

        //从字符串变回ArrayList
        List<String> names2 = Arrays.asList(str2.split(","));
        for(String name:names2)
        {
            System.out.println(name);
        }

        //StringUtils 可以支持更多数据类型
        List<Integer> ids = new ArrayList<Integer>();
        ids.add(1);
        ids.add(3);
        ids.add(5);
        String str3 = StringUtils.join(ids, ",");
        System.out.println(str3);
    }

}
```

代码(8) EscapeString.java


```java
public class EscapeString {

    public static void main(String[] args) {
        String str = "He didn't say, \"Stop!\"";

        //转义
        String escapedStr = StringEscapeUtils.escapeJava(str);
        System.out.println("escape" + ":" + escapedStr);

        //从转义字符串转回来
        String str2 = StringEscapeUtils.unescapeJava(escapedStr);
        System.out.println("unescape" + ":" + str2);
    }
}
```

代码(9) GuavaUtil.java


```java
public class GuavaUtil {
    public static void main(String[] args) throws Exception {
        List<Integer> list = new ArrayList<Integer>();
        list.add(123);
        list.add(456);
        System.out.println(list);

        //直接初始化List数组
        List<Integer> integers = Lists.newArrayList(123, 456);
        System.out.println(integers);

        //拆分字符串，忽略空字符串
        Iterable<String> split = Splitter.on(',')
                .trimResults()
                .omitEmptyStrings()
                .split("123,321,,   abc");

        for (String s : split) {
            System.out.println(s);
        }
```

代码(10) GuavaUtil.java


```
        String a = "123,321,,   abc";
        String[] as = a.split(",");

        for(int i=0;i<as.length;i++)
        {
            if(null == as[i] || as[i].length()<=0)
            {
                continue;
            }
            else
            {
                System.out.println(as[i].trim());
            }
        }
    }
}
```

代码(11) String2InputStream.java


```java
public class String2InputStream {

    public static void main(String[] args) {
        //构造字符串列表
        List<String> names = new LinkedList<String>();
        names.add("Xiaohong");
        names.add("Xiaoming");
        names.add("Daming");
        names.add("Xiaohei");

        //合并为一个字符串，以逗号相连
        String nameStr = String.join(",",names);

        //将字符串作为默认的输入流
        InputStream in = IOUtils.toInputStream(nameStr, Charsets.toCharset("UTF-8"));
        //重置系统的输入流
        System.setIn(in);

        //模拟键盘输入 这也是OJ平台测试用例输入的原理
        //此处也可以换成一个文件输入流
        Scanner sc=new Scanner(System.in);
        sc.useDelimiter(",");
        while(sc.hasNext())
        {
            System.out.println(sc.next());
        }

    }
}
```

谢 谢！